20261009 智能大数据 fxy 笔试

基于大语言模型专利文本特征的企业经济结果研究

—— 实验报告

姓名：冯馨逸

学号：1026006945

院系：武汉理工大学经济学院 数字经济与人工智能双学士 2602 班

提交日期：2026 年 10 月　日

摘要

本文基于 152 家中国 A 股上市公司的 117,711 条专利数据，检验「专利文本蕴含多个相互独立的信息维度」这一假设，并进一步考察其中一个关键维度——跨领域整合度——与企业经济结果之间的关系。研究分四个部分展开：（i）用 12 个数量类专利特征在三种模型设定下考察其解释与预测能力；（ii）用大语言模型从专利文本提取技术新颖性、科学基础强度、跨领域整合度和商业化距离四个语义维度，检验其相对基准特征的增量解释力与正交信息；（iii）逐个检验各维度的相对重要性；（iiii）在控制企业、年份、行业×年份、地区×年份四类固定效应的条件下，用聚类稳健标准误与双重机器学习识别跨领域整合度对企业结果的影响。

主要发现：（1）数量类特征在跨公司维度上几乎不具备解释力（R^2 接近 0 或为负），但在公司内部可解释约 18% 的总资产净利润率波动，且线性模型优于非线性模型；（2）语义特征中 45%–65% 的变异无法被数量特征解释，确实捕捉到正交信息，但增量解释力有限（约 +0.01）；（3）四个维度中跨领域整合度的贡献排名第一；（4）跨领域整合度与主营业务收入增长率存在负向相关（主回归 -4.14，p = 0.034；LASSO-DML -4.28，p = 0.020），但该结果对方法设定敏感（随机森林-DML p = 0.102），且核心指标的测量可靠性尚未充分建立（见 4.3 节）；对融资约束与盈利能力的估计均不显著。综合而言，本文将该结果视为有待进一步验证的初步发现，而非稳健的因果结论。

关键词：专利文本特征；大语言模型；跨领域整合度；双重机器学习；固定效应

一、引言与研究设计

1.1 研究问题

专利文本中蕴含着丰富但难以结构化的技术信息。这些信息是否包含多个相互独立的维度？如果是，哪个维度最能反映企业的经营结果？本文以中国 A 股上市公司的专利数据为样本回答这两个问题。

1.2 研究设计

题目将研究拆为四个部分，四者构成「找线索 → 下判断」的递进关系：（i）和（ii）分别考察数量类与语义类专利特征的解释与预测能力；（iii）比较各语义维度的相对重要性，为（iiii）选定核心解释变量提供依据；（iiii）则对选出的核心维度做严格的计量识别。

表 1　研究设计的四个部分

部分	要回答的问题	对应章节
(i)	数量类专利特征对经济结果有没有差异化解释与预测能力？关系是线性还是非线性？	3.1 / 4.1
(ii)	大语言模型提取的语义特征有没有增量解释力？含不含正交信息？	3.2 / 4.2
(iii)	四个语义维度里哪个最重要？	3.3 / 4.3
(iiii)	跨领域整合度与企业经济结果之间是什么关系？	3.4 / 4.4

二、数据

2.1 数据来源

表 2　数据来源与规模

数据	来源	规模
专利数据	题目提供的 152 个 Excel 文件（每家公司一个）	117,711 条专利
公司财务数据	akshare 财经数据接口（东方财富 / 巨潮资讯）	144 家 × 86 个变量，2015–2025
行业与地区	巨潮资讯公司概况接口（stock_profile_cninfo）	143 家公司
企业成立日期	同上	143 家公司

2.2 数据处理流程

数据处理依次经过六步：① 从 152 个 Excel 中提取每家公司对应的股票代码；② 用 A 股官方代码表逐条校验；③ 抓取企业财务数据；④ 检查各变量的年份覆盖率，筛选可用的结果变量；⑤ 将专利明细聚合到「公司—年份」层面的 12 个特征；⑥ 与财务数据合并生成主数据集。

2.3 数据质量校验

数据处理过程中发现并处理了三个问题，记录如下。

表 3　数据质量校验的三个发现

#	发现的问题	处理方式
1	股票代码提取有误：大富科技被误提取为 300127，与成都银河磁体重复；东富龙的文件内容与文件名不符（实为华中数控的专利）；包头天和磁材代码为空	修正大富科技为 300134；剔除东富龙与包头天和磁材
2	首次合并仅得到 249 个观测，样本异常塌缩。排查两轮后定位到「销售毛利率」这一变量 2019 年后完全缺失（覆盖率仅 19.8%）	更换为覆盖率 99.9% 的「资产负债率」，样本恢复至 1,270 个观测
3	北交所 / 新三板股票（839708 等 6 家）不在 akshare 覆盖范围内	从 150 家中剔除，最终得到 144 家可用公司

2.4 语义特征提取

语义特征由智谱 GLM-4-Flash 大语言模型对每条专利的标题与摘要逐条评分得到。提示词经过四轮迭代：v1 采用抽象锚点，结果显示 85% 的样本被打为 3 分，缺乏区分度；v2 增加示例但未见改善；v3 改为 1–10 分制并加入专利类型线索，取值种类从 3 种提升至 8 种；v4 修正「商业化距离」维度的定义错误后定稿。最终对 12,166 条专利完成打分。各版本提示词全文见附件 A。

关于打分的抽样规则：受 token 预算限制，本文未对全部 117,711 条专利打分，而是按「公司—年份」分层随机抽取，每个公司—年份最多 10 条（PER_FIRM_YEAR = 10），最终覆盖 12,166 条，约占专利总数的 10.4%。公司—年份层面的语义特征由这最多 10 条专利的评分取均值得到。需要说明的是，该抽样规则对聚合结果的代表性与加权方式未做敏感性检验，这是本文的一个局限。

2.5 最终样本

表 4　样本口径

口径	公司数	观测数	年份范围
原始专利文件	152	—	—
代码校验与剔除后	144	—	—
主数据集（（i）–（iii））	143	1,270	2015–2025
（iiii）回归样本（含 SA 指数）	142	1,259	2015–2025

注：（i）–（iii）部分样本为 1,270 个观测；由于 SA 指数需要企业成立日期，有 1 家公司缺失该信息，故（iiii）部分回归样本为 1,259 个观测。

三、方法论

3.1 (i) 基准特征的差异化解释与预测能力

我们从专利明细中构造了 12 个数量类特征，覆盖题目列举的 7 类中的 6 类：专利数量（ln 专利数）、权利要求数、引用次数、发明人数量、专利家族规模、IPC 分类，以及从数据中补充的平均首权字数、平均合享价值度、平均技术先进性、平均技术稳定性、平均保护范围、平均文献页数。

模型方面，线性模型采用普通最小二乘（LinearRegression），非线性模型采用随机森林（300 棵树），两者在完全相同的训练 / 测试集上比较。为回答「差异化解释」的问题，设置三种模型设定：① 原始数据；② 年度去均值；③ 公司内去均值（等价于企业固定效应）。由于同一公司有 11 年数据，为避免信息泄漏，训练集与测试集按公司分组划分（GroupShuffleSplit，8:2）。

3.2 (ii) 语义特征的增量解释力与正交信息

从题目给出的 8 个候选维度中选定 4 个：技术新颖性、科学基础强度、跨领域整合度、商业化距离。选择标准是与基准数量特征的重叠最小——因为（ii）要验证的正是「与基准特征正交的信息」。据此放弃了「权利要求广度」（基准已有权利要求数）与「合作网络属性」（基准已有发明人数）。

增量解释力的检验设置三组特征：A = 仅 12 个数量特征；B = 数量特征 + 4 个语义特征；C = 仅 4 个语义特征。三组使用完全相同的模型（RidgeCV，正则化强度由交叉验证确定）与交叉验证方案（5 折、按公司分组），以 B − A 作为语义特征带来的增量。

正交信息的检验采用正交化方法（等价于残差回归）：以 12 个数量特征回归每一个语义特征，以 $1-R^2$ 衡量其正交信息占比。

3.3 (iii) 各维度的相对重要性

将 4 个语义维度逐个加入基准特征（一次只加一个，其余三个不加），比较每个维度单独带来的增量，以识别贡献最大的维度。模型与交叉验证方案与 3.2 节完全一致，保证四组之间唯一的差别就是加入了哪一个维度。

3.4 (iiii) 计量识别策略

核心解释变量 x 选用跨领域整合度，依据是 3.3 节的结果（它在三个结果变量上的增量排名均为第一）。被解释变量 y 共四个：SA 指数（融资约束，主）、资产负债率（杠杆）、总资产净利润率

（盈利）、主营业务收入增长率（成长）。其中 SA 指数按 Hadlock & Pierce（2010）的方法构造：$SA = -0.737 \times Size + 0.043 \times Size^2 - 0.040 \times Age$，其中 Size = ln(总资产 / 百万元)，Age 为企业成立年数。

基准回归方程设定为：

$$y = \theta \times \text{跨领域整合度} + \text{控制变量} + \text{企业 FE} + \text{年份 FE} + \text{行业}\times\text{年份 FE} + \text{地区}\times\text{年份 FE} + \text{误差}$$

控制变量为 12 个数量类专利特征。四类固定效应中，行业×年份与地区×年份的作用是吸收行业与地区层面的时变冲击。标准误在企业层面聚类，并另外检验了行业、地区两种聚类层级的稳健性。

识别策略采用双重机器学习（DML）。DML 的做法是：先用机器学习分别拟合 E[y|Z] 与 E[x|Z]（Z 为全部控制变量与固定效应），再对两个残差进行回归，所得系数 θ 对模型误设更稳健。我们使用 5 折交叉拟合，并分别以随机森林与 LASSO 作为学习器互相验证。为避免 DML 与基准回归的固定效应设定不一致，我们先用交替投影法将全部变量对四类固定效应偏回归，再对残差执行 DML。

四、实验结果

4.1 (i) 数量类特征的差异化解释与预测能力

表 5 三种设定下的模型表现（R^2）

设定	线性模型	随机森林	说明
① 原始	-0.051 / 0.026 / 0.039	低于线性	跨公司维度几乎无解释力
② 年度去均值	-0.165 / — / —	—	剔除年度冲击后仍差
③ 公司内去均值	0.180 / 0.058 / 0.065	0.149（ROA）	公司内可解释约 18%

注：三个数字依次对应总资产净利润率 / 主营业务收入增长率 / 资产负债率。

三个结论：① 跨公司维度上，12 个数量特征几乎不具备解释力（R^2 接近 0 甚至为负）；② 公司内维度上，特征可解释约 18% 的总资产净利润率年度波动；③ 在 9 组比较中线性模型胜出 8 组，说明专利特征与企业结果之间主要是线性关系，随机森林在 1,270 个观测的样本量下出现过拟合。

4.2 (ii) 语义特征的增量解释力与正交信息

表 6 语义特征的增量解释力

设定	被解释变量	A 仅数量	B 数量+语义	增量(B−A)
① 原始	总资产净利润率	0.0145	0.0249	+0.0104
① 原始	主营业务收入增长率	0.0232	0.0259	+0.0027
③ 公司内	总资产净利润率	0.0976	0.1096	+0.0120
③ 公司内	主营业务收入增长率	0.0385	0.0383	-0.0002

增量方向为正，但幅度很小（0.1–1.2 个百分点）。这说明语义特征确实携带了新信息，但对企业财务结果的预测能力提升有限。

表 7 语义特征的正交信息占比

语义维度	被数量特征解释的 R^2	正交部分（$1-R^2$）
技术新颖性	0.554	0.446
科学基础强度	0.449	0.551
跨领域整合度	0.446	0.554
商业化距离	0.349	0.651

四个语义特征中 45%–65% 的变异无法被数量特征解释，平均相关系数仅 0.21，说明大语言模型确实捕捉到了正交信息。

稳健性检验：为检验题目「多个相互独立的维度」这一前提，我们额外做了一组对照实验——将四个维度拆成四次独立调用（每条专利调用 4 次），与一次调用四个维度相比，维度间平均相关系数并未下降（0.725 对 0.679）。这说明维度间的高相关是专利的客观属性，而非提示词设计造成的锚定效应。据此如实报告：在本研究样本中，四个语义维度并非相互独立（相关系数 0.66–0.92），这一发现与题目前提存在张力，改进方向见 5.3 节。

4.3 语义打分的人工可靠性检验（新手探索性检验）

题目（ii）要求使用大语言模型提取结构化特征，但并未要求检验其打分质量。为评估语义评分的可靠性，本文补充了一项人工验证：从 12,166 条已打分专利中随机抽取 15 条，由作者在不知晓 AI 评分结果的条件下，依据 v4 提示词的评分标准独立评分，再与 AI 评分逐一比对。

需要特别声明评分者的身份限制：本节的人工评分由作者本人独立完成。作者为一年级本科生（数字经济与人工智能双学士专业），此前未接触专利文献、技术分类或计量经济学，未接受评分培训，也无专利审查或技术管理经验。因此本次检验实质上是「无领域背景的新手 vs 大语言模型」的对比，而非文献中标准的「领域专家 vs 模型」效度检验。

该身份限制带来三层后果。其一，作者在「跨领域应按技术类别还是应用领域计数」上的犹豫（见第 10 条样本的分歧），既可能反映模型打分偏差，也可能反映评分者对构念定义的误读，两种解释在现有设计下均无法排除。其二，样本仅 15 条、评分者仅 1 人、无复核与仲裁，相关系数的置信区间极宽，r = 0.184 在统计上无法与 r = 0.6 相区分。其三，即使人工评分与模型一致，也不能作为模型可靠的正向证据 —— 因为参照系本身不可靠。

因此本节结论只能作为「跨领域整合度的测量效度尚未建立」的警示信号，不能视为对模型效度的独立验证。规范做法是引入至少一名专利代理人或技术管理方向的研究生作为第二评分者，按双评分者随机样本计算 ICC(2,1) 或 Krippendorff's α 并报告置信区间。这是本报告在测量层面最实质的局限。

检验结果揭示三点：

（1）科学基础强度的一致性最高（r = 0.852），说明该维度的定义明确、人工与模型判断可以互相印证。

（2）跨领域整合度的一致性最低（r = 0.184），人工评分与模型评分几乎不相关。这一结果值得特别重视，因为跨领域整合度正是（iiii）部分的核心解释变量。典型分歧见第 10 条样本「一种以图搜图的车辆识别方法及系统」：作者将其视为计算机视觉单一领域（2 分），模型则识别出视觉、交

通、软件三类（7 分）。这一分歧的根源在于提示词未明确「跨领域」是按「技术类别」计数还是按「应用领域」计数。

（3）人工评分整体低于模型评分约 1 分（3.22 对 4.18），四个维度上均为同一方向。这可能是人工评分偏保守所致，也可能反映模型存在系统性高估，仅凭本检验无法区分二者。

本项检验的意义在于：它表明本文主结论所依赖的核心指标，在测量层面存在未被充分解决的不确定性。若跨领域整合度的测量误差较大，则 4.5 节中 -4.14 这一估计值可能被低估（测量误差通常使系数向 0 衰减）。这一局限已补充至 5.3 节。

需要说明的是，本检验仅基于 15 个样本，相关系数的估计精度有限，上述结论应谨慎对待。此外，人工评分由本文作者完成，作者并非专利领域专家，其判断本身也存在误差。

表 8　人工评分与 AI 评分的一致性

语义维度	人工均分	AI 均分	相关系数 r	完全一致	平均绝对差
技术新颖性	4.13	5.00	0.496	5/15	1.53
科学基础强度	3.80	4.80	0.852	6/15	1.00
跨领域整合度	2.27	2.93	0.184	5/15	1.33
商业化距离	2.67	4.00	0.565	2/15	1.87
合计	3.22	4.18	0.614	—	—

4.4　(iii) 各维度的相对重要性

表 9　四个语义维度逐个加入带来的增量

加入的维度	ROA 增量	营收增长增量	资产负债率增量	排名
跨领域整合度	+0.0122	+0.0067	-0.0006	★ 第 1
科学基础强度	+0.0060	+0.0044	+0.0012	第 2
技术新颖性	+0.0053	+0.0004	+0.0036	第 3
商业化距离	+0.0053	-0.0005	-0.0059	第 4

跨领域整合度在三个结果变量上都排名第一或并列第一，是最重要的语义维度。这一结果为 4.4 节选定核心解释变量提供了依据。

4.5　(iiii) 跨领域整合度与企业结果

表 10　主回归结果（四类固定效应 + 企业层面聚类稳健标准误）

被解释变量	系数	聚类标准误	p 值	结论
SA 指数（融资约束，主）	+0.0011	0.0051	0.831	不显著
资产负债率（杠杆）	-0.229	0.795	0.773	不显著

总资产净利润率（盈利）	+0.014	0.445	0.974	不显著
主营业务收入增长率（成长）	-4.142	1.930	0.034	5% 显著为负

在控制四类固定效应及 12 个数量类专利特征后，跨领域整合度与主营业务收入增长率呈负向相关（系数 -4.14，p = 0.034），即跨领域整合度每提高 1 分，企业当期主营业务收入增长率平均下降约 4.1 个百分点；而对融资约束的两个代理（SA 指数、资产负债率）及盈利能力（总资产净利润率）的估计均不显著。

稳健性检验共四组：① 滞后一期解释变量（缓解反向因果），系数方向一致，资产负债率上为 -1.48（10% 边际显著）；② 更换聚类层级（企业 / 行业 / 地区），结论一致；③ 逐个语义维度替换 x，四个维度对营收增长率的系数全部为负，跨领域整合度最强；④ 更换机器学习学习器。

补充检验：-4.14 是否来自共同因子。

上述四个语义维度两两相关系数达 0.66–0.92，其第一主成分解释了四维总方差的 84%，存在明显的共同因子。为判断 -4.14 是否为该共同因子的代理，本文补做三组同规格回归（同被解释变量、同控制变量、同固定效应、同聚类层级），仅更换解释变量。

表 10-A　补充检验：剥离共同因子后的整合度效应（被解释变量：主营业务收入增长率）

设定	解释变量	系数	聚类标准误	p 值
(1) 原设定（复现）	x_integration	-4.138	1.929	0.034 **
(2) 四维同时放入	x_integration	-4.027	3.155	0.204
(3) 仅共同因子	PC1（四维第一主成分）	-1.898	0.867	0.030 **
(4) 剥离另外三维后的整合度	x_int_resid	-4.123	3.264	0.209
(5) 整合度 + 共同因子	x_integration	-2.450	4.016	0.543
(5) 整合度 + 共同因子	PC1	-0.935	1.811	0.606

注：(1) 行复现了 4.5 节的主结果，说明补充检验与原设定可比。PC1 为四个语义维度标准化后的第一主成分，解释方差比例 0.840。

结果与判读：在剥离另外三个维度的共同变异后，跨领域整合度的点估计几乎不变（-4.123 对 -4.138），但标准误由 1.929 增至 3.264，系数不再显著（p = 0.209）；而单独以第一主成分作为解释变量时，系数为 -1.898（p = 0.030）。这组证据表明：-4.14 的显著性主要来自四个维度共享

的那部分变异，而非跨领域整合度独有的变异。本文因此不能把该结果归属于「跨领域整合度」这一个维度。

需要说明两点。其一，残差化后的点估计并未消失（仍在 -4.1 左右），变化的是精确度而非方向；因此更准确的表述是「剔除共同变异后，剩余变异不足以支撑统计显著」，而非「效应不存在」。其二，本节检验仅用于判断 -4.14 是否由共同因子驱动，不改变 4.3 节所指出的测量效度未经验证这一根本局限。

表 11　双重机器学习结果与主回归的对比

被解释变量	主回归	DML-随机森林	DML-LASSO
SA 指数（融资约束）	+0.0011 (p=0.83)	+0.0029 (p=0.49)	+0.0015 (p=0.72)
资产负债率	-0.229 (p=0.77)	-0.013 (p=0.98)	-0.273 (p=0.65)
总资产净利润率	+0.014 (p=0.97)	+0.231 (p=0.59)	+0.031 (p=0.94)
主营业务收入增长率	-4.142 (p=0.034)	-3.109 (p=0.102)	-4.282 (p=0.020)

双重机器学习的结果与主回归方向一致，但强度不一致：对营收增长率的估计为 -3.11（随机森林）（p = 0.102，未达 10% 显著）与 -4.28（LASSO，p = 0.020）；对其余三个结果变量均不显著。值得注意的是，第一版 DML 因未控制行业×年份与地区×年份固定效应，在 SA 指数上给出了与主回归相反的显著结果（-0.0191）；在补齐固定效应设定后，两者结论完全一致。这说明是方法设定上的差异，而非数据本身导致了原先的矛盾。

五、讨论

5.1 主要发现

（1）语义特征含有正交信息，但增量解释力有限。

大语言模型从专利文本中提取的四个语义维度，确实携带了数量类特征无法捕捉的信息：45%–65%的变异无法被 12 个数量特征解释，平均相关系数仅 0.21。但这一「新信息」对预测企业财务结果的贡献有限 —— 加入四个语义维度后，模型 R^2 仅提高约 0.01。

需要补充的是：增量幅度小，也可能是本次研究的观测数据偏少所致 —— 1,270 个观测对于「从文本语义预测财务结果」这类高噪声任务而言样本量有限，因此不宜据此断定语义特征缺乏价值。

这一结果的含义是双向的。一方面，它说明用大语言模型处理非结构化文本、并转化为可量化指标这条路径是可行的，语义特征不是数量特征的简单重复；另一方面，它也提示，对于「预测企业财务表现」这类任务，文本语义信息的作用不宜被高估。

（2）四个语义维度在本样本中并不独立。

本文检验了题目「多个相互独立的维度」这一前提。结果显示，四个语义维度两两相关系数达 0.66–0.92，存在明显的共同因子。为排除方法性原因，我们设计了一组对照实验：将四个维度拆成四次独立的 API 调用，与一次调用四个维度相比，维度间平均相关系数并未下降（0.725 对 0.679）。因此高相关更可能源于专利本身的客观属性 ——一项技术若足够新颖，往往同时具有较强的科学基础、较高的跨领域程度与较远的商业化距离。这一发现与题目前提存在张力，本文如实报告。

（3）跨领域整合度是最重要的语义维度。

在将四个维度逐个加入基准特征的检验中，跨领域整合度在三个结果变量上的增量排名均为第一，因此被选为（iiii）部分的核心解释变量。

（4）跨领域整合度与主营业务收入增长率呈负向相关，但证据强度有限。

在控制企业、年份、行业×年份、地区×年份四类固定效应及 12 个数量类专利特征后，跨领域整合度的估计系数为 -4.14（$p = 0.034$）；在 LASSO-DML 下为 -4.28（$p = 0.020$），在随机森林-DML 下为 -3.11（$p = 0.102$）。三个估计方向一致，但仅两个达到常规显著水平。因此本文的表述是「存在负向相关」，而非「稳健的负向效应」。

对这一结果存在两种竞争性解释，本文无法在现有证据下区分。第一种是实质解释：跨领域整合度高的技术通常处于更早期、更远离商业化应用的阶段，短期内难以直接转化为收入，甚至可能因研

发投入挤占资源而对当期增长形成拖累。第二种是方法学解释：四个语义维度的两两相关系数达0.66–0.92，存在明显的共同因子；（iii）的替换检验显示四个维度对营收增长率的系数全部为负，因此 -4.14 也可能只是「技术复杂度」这一类共同因子的代理，而非跨领域整合度独有的效应。本文如实并列这两种解释，不对其中任一种作定论。

此外，控制变量中 ln 专利数对资产负债率的系数为 -2.69（t = -4.34，p<0.001），即专利数量越多的企业杠杆越低。这一现象可能反映技术型企业更依赖股权融资而非债务融资。

5.2 内生性讨论

本文的估计可能受三类内生性问题影响。

表 12 内生性的三个来源及本文的处理

内生性来源	本文的处理	仍存在的局限
反向因果：业绩好的企业才有资源投入跨领域研发	① 企业固定效应吸收不随时间变化的企业异质性；② 滞后一期检验（以 t−1 期的 x 解释 t 期的 y）	滞后检验只能缓解当期反向因果，无法完全排除
遗漏变量：管理层能力、技术战略等同时影响专利特征与企业业绩	四类固定效应吸收了不随时间变化的部分；12 个数量类专利特征控制了专利的数量与质量维度	随时间变化的企业层面遗漏变量（如当年的战略调整）无法排除
测量误差：大语言模型的语义评分存在噪声	四个维度交叉验证；双重机器学习使用两种学习器（随机森林、LASSO）	测量误差会使系数向 0 衰减，即低估真实效应

需要特别说明的是：识别策略的有效性依赖于条件外生性假设，即给定控制变量 Z 之后，x 中与 Z 无关的变异与误差项不相关。该假设无法被完全检验，因此本文的结论只宜解释为相关关系，而非严格的因果关系。

5.3 局限

（1）样本规模有限。本文最终样本为 142 家公司、1,259 个观测，在控制四类固定效应后自由度较为紧张，标准误偏大。因此若干不显著的估计可能源于检验力不足，而非确实不存在关系。

（2）融资约束代理的识别力有限。SA 指数在控制企业固定效应后仅保留约 19% 的原始变异（标准差由 0.300 降至 0.056），这与其构造方式有关 —— SA 指数主要由企业规模与年龄决定，而这两个变量在企业内部几乎不随时间变化，因此组内识别力较弱。

（3）行业与地区经过合并。本文将 24 个行业分类合并为 6 大类、31 个省级行政区合并为 4 大区，以避免固定效应单元过小导致估计不稳，但这一处理可能掩盖组内异质性。

（4）未能使用工具变量法。严格的因果识别需要外生的工具变量，本文样本中缺乏可信的、只影响 x 而不直接影响 y 的变量，因此以高维固定效应、滞后解释变量与双重机器学习作为识别策略。

（5）核心指标的测量可靠性存在不确定性。4.3 节的人工验证显示，且该验证本身由无专利背景的一年级本科生独立完成、单人打分无复核，参照系可能失效 —— r = 0.184 既可能反映模型偏误，也可能反映评分者偏误，二者无法区分。4.3 节的人工验证显示，跨领域整合度这一维度的人工评分与模型评分几乎不相关（r = 0.184），说明该指标的测量定义仍有模糊之处。测量误差通常使回归系数向 0 衰减，因此 4.4 节中 -4.14 的估计值可能被低估。

六、结论

本文以 152 家中国 A 股上市公司的 117,711 条专利数据为样本，检验了专利文本中蕴含多重信息维度这一假设，并进一步考察了其中一个关键维度 —— 跨领域整合度 ——与企业经济结果之间的关系。在数量类特征方面，本文发现其在跨公司维度上几乎不具备解释力，但在公司内部可解释约 18% 的总资产净利润率波动，且关系是线性的。在大语言模型提取的语义特征方面，四个维度中 45%–65% 的变异无法被数量特征解释，但增量解释力有限（约 +0.01）。

在计量识别层面，跨领域整合度的估计系数为 -4.14（p = 0.034）。然而本文做了两项使该结果不能作为主结论保留的检验。第一，四个语义维度的第一主成分解释了其总方差的 84%；在剥离共同变异后，整合度的系数仍在 -4.1 左右但不再显著（p = 0.209），而共同因子单独放入时显著（p = 0.030）—— 说明该显著性主要来自共同因子，而非跨领域整合度独有的效应。第二，4.3 节的人工检验显示该指标的测量效度尚未建立。

因此，在与上述两项检验一致的范围内，本文能够支持的结论是：在中国 A 股上市公司样本内，专利文本的语义特征与主营业务收入增长率呈负相关；该负相关主要来自四个语义维度背后的共同质量因子，跨领域整合度并非其独立来源。该负相关的具体经济机制，在现有样本与测量条件下无法识别。

本文不做因果解释。上述关系的进一步识别，需要在更大样本、经双评分者协议验证的评分标准，以及外生工具变量的条件下完成。

七、作者本人的工作与收获

本项目采用「工具执行、作者审核与深挖」的工作方式：数据处理与分析代码在人工智能工具的协助下实现，作者负责需求提出、方案把关、过程核对与独立验证。本章说明作者具体完成了哪些工作、以及由此获得的收获。

7.1 作者在项目实施中的工作

7.1.1 数据获取与过程核对

- 运行全部数据抓取与清洗脚本，并逐阶段核对输出结果
- 对股票代码校验中发现的 3 处问题（大富科技代码误提取、东富龙文件与内容不符、包头天和磁材代码为空）逐条确认处理方式
- 对样本量异常塌缩（由 1,500 降至 249 个观测）的现象提出疑问并参与定位，最终确认原因是「销售毛利率」变量 2019 年后完全缺失

7.1.2 方案决策的把关

- 在计量工具选择上，查阅 Stata 正版定价（官方学生版 48 美元/半年、中国区官方代理约 1,000 元），识别并排除了两个破解下载站点，最终与项目联系人确认采用功能等价的 Python 实现，同时保留可运行的 do 文件与数据
- 确认语义特征提取的提示词迭代方向，审核四版提示词的评分锚点与正交性检验方案

7.1.3 对分析结果的审核与质疑

作者在审核过程中提出 30 余项关于方法细节与表述的疑问，其中 6 项直接改变了成果内容：

表 13　作者提出并导致修改的 6 项质疑

#	作者提出的问题	产生的结果
1	发现独立性检验输出的两个相关系数矩阵完全相同	定位到检验脚本中的一处实质错误（两个变量被错误地计算为同一份数据），修正后该检验才真实成立
2	指出「增量解释力有限」也可能是观测数据过少所致	该判断被采纳并写入 5.1 节
3	追问：既然（i）证明关系是线性的，（iiii）为何使用随机森林？两者是否矛盾	促使明确「线性是（i）的结论、随机森林是（iiii）的工具」这一区分，成为结果解读的关键说明
4	追问：（ii）（iii）（iiii）的 x 与 y 各不相同，为何称使用了同一种方法	暴露出原稿对「方法」一词的表述不清，改写为「分析流程不变、x 与 y 可变」的框架
5	追问：数据准备阶段为何不填观测数与年份范围	补充了表 4 的注释，说明样本结构在合并前尚未形成
6	在人工评分检验中发现跨领域整合度的人机一致性仅 0.184	见 4.3 节，构成对主结论的实质性保留

7.1.4 独立完成的验证工作

4.3 节「语义打分的人工可靠性检验」由作者独立完成：自行设计验证方案、随机抽取 15 条专利、在不知晓模型评分的条件下独立打分、完成比对与归因分析。该节提出的结论（核心解释变量的测量可靠性不足）直接影响了本文对主结论的评价。

7.2 学习收获

作者此前未接触过计量经济学与实证研究流程。通过本项目，在以下方面建立了初步认识。

（1）实证研究的完整链条。

从原始资料出发，需要依次完成：确定分析单位（专利级还是公司级还是公司—年份级）、由原始数据聚合出特征、将不同来源的数据按共同键合并、选择合适的估计方法、最后才是结论与局限。其中「确定分析单位」这一步决定后续全部设计。

（2）固定效应的作用。

理解了控制企业、年份、行业×年份、地区×年份四类固定效应的意义：把各类共同冲击（企业自身禀赋、年度环境、行业与地区的时变因素）提前扣除，避免将其误认为解释变量的作用。

（3）因果识别的基本概念。

理解了内生性的三个来源（反向因果、遗漏变量、测量误差），以及高维固定效应、滞后一期检验、双重机器学习各自能够处理其中的哪一部分、哪些部分无法处理。

（4）测量可靠性的重要性 —— 本项目最重要的收获。

一个回归结果是否可信，首先取决于核心指标的测量是否可靠。在 4.3 节的人工检验中，跨领域整合度的人机一致性仅为 0.184，而它正是主回归的核心解释变量。这意味着 -4.14 这一估计值的可信度取决于该指标的测量质量，而不取决于回归方法本身。这一认识是作者在本项目中最主要的收获。

（5）工具与判断的关系。

工具可以高效地完成执行层面的工作，但「这个定义是否清楚」「这个结果是否可信」「这里可能哪里出错」这类判断无法由工具代替，只能由研究者提出。本项目中作者提出的 30 余项质疑，多数指向原稿的表述漏洞或方法细节不清之处，其中 1 项定位到了脚本中的实际错误。

（6）检验应贯穿研究全过程，而不是留到最后。

本项目最深刻的教训来自时序问题：测量效度的检验（4.3 节）与共同因子的检验（4.5 节表 10-A）都是在报告基本完成之后才补做的。如果这两项检验在语义特征提取完成之后、进入回归之前就完成，那么（iiii）部分的设定本可以据此调整，而不必在最后对已完成的结论做降级处理。这说明：检验不是收尾工作，而是每一步的组成部分 —— 每做完一步就检验一步，成本远低于最后补救。

（7）用多个模型互相验证，能发现单一视角看不到的问题。

本报告最后一轮的六项修改，是由另一个大语言模型以审稿人视角提出的五个问题驱动的。其中「-4.14 可能是共同因子的代理」这一条，直接导致了补充检验的补做与主结论的降级。把工具的输出交给另一个工具去质疑，是一种成本很低、收益很高的自我审查方式。但也要注意：模型会提出不成立的批评（例如指责本文未做缩尾处理，而实际上做了、只是未在报告中写明），因此交叉验证的结果仍需人工判断。

（8）最根本的一条：方法可以借助工具，知识储备不能。

本项目全程遇到的困难，归根结底都可以追溯到知识储备不足。对固定效应、残差、标准误这些概念的理解，是在反复提问之后才逐步建立的；而正是因为缺少统计学与计量经济学的基础，作者无法在研究进行中自行判断「这里应当补一个什么样的检验」。工具可以执行，也可以解释，但无法代替研究者产生「我知道这里需要检验什么」这一判断。因此，补足统计学与计量经济学的基础，是作者下一阶段的首要任务；熟练掌握工具是其次。

7.3 关于工具使用的说明

本项目的分析代码与报告初稿在人工智能工具的协助下生成，作者负责需求提出、方案审核、过程核对与独立验证。作者认为这一工作方式本身并不构成问题，关键在于研究者是否对结论承担责任 —— 包括能否指出结果的适用边界、能否发现工具输出中的错误。

4.3 节的验证工作与 7.1.3 节列出的质疑，是作者对这一责任的履行；而 5.3 节第（5）条关于核心指标测量可靠性的保留，则说明作者对本文结论持有的是有边界的判断，而非无保留的接受。

附件 A 提示词版本说明

四版提示词全文见项目目录 prompts/prompt_v1.txt ~ prompt_v4.txt。各版本改动与效果如下。

表 A1 提示词四版迭代

版本	改动	效果

v1	抽象锚点，1–5 分制	85% 打 3 分，缺乏区分度
v2	增加 few-shot 示例	仍约 75% 打 3 分，未见改善
v3	改为 1–10 分制；加入专利类型线索；增加反聚集指令	取值种类从 3 种提升至 8 种，标准差升至 2.14
v4	修正「商业化距离」定义：明确该维度与技术含量无关，外观设计应给 1–2 分	采用为最终版本

附件 B　数据字典

表 B1　主要变量说明

变量名	含义	来源
firm_id / year	企业编号 / 年份	—
industry / region	行业大类（1–6）/ 地区大区（1–4）	公司_行业地区.csv
y_sa	SA 融资约束指数（越大越受约束）	按 Hadlock & Pierce (2010) 计算
y_lev	资产负债率（%）	企业财务数据
y_roa	总资产净利润率（%）	企业财务数据
y_growth	主营业务收入增长率（%）	企业财务数据
x_integration	跨领域整合度（大语言模型语义特征）	llm_scores_v4.csv 聚合
x_novelty / x_science / x_distance	技术新颖性 / 科学基础强度 / 商业化距离	同上
ln_patent … ipc_fields	12 个数量类专利特征（控制变量）	公司年度特征.csv

附件 C　可复现性说明

运行环境：Windows 11 + Python 3.14.8；主要依赖 pandas、numpy、scikit-learn、pyfixest、requests、akshare，版本见 requirements.txt。

数据版本：专利明细共 117,711 条；大语言模型打分使用 v4 提示词，共 12,166 条专利级评分，消耗 1,777 万 token，耗时约 50 分钟（WORKERS=10，YEAR_MIN / YEAR_MAX = 2015 / 2025，PER_FIRM_YEAR=10）。

运行顺序：extract_codes.py → check_codes.py → fetch_financials.py → check_coverage.py → build_patent_table.py → build_dataset.py → model_i.py → score_patents.py → review_scores.py → model_ii.py → fetch_industry_region.py → fetch_found_date.py → build_sa_index.py → model_iiii.py → model_iiii_dml_fixed.py。

Stata 复现：stata/main_dataset.dta 为 Stata 原生格式数据集（变量名全英文），stata/iiii_regression.do 为完整 do 文件，包含描述性统计、主回归、逐维度回归、滞后检验、聚类层级稳健性检验与结果导出。持有 Stata 授权者运行该 do 文件即可复现 4.4 节的全部结果。

随机性控制：所有涉及随机划分的步骤均固定随机种子（seed=42）；大语言模型打分使用 temperature=0。

附件 D　交付清单

表 D1　交付物清单

#	交付物	位置
1	GitHub 仓库（代码与说明）	待创建
2	实验报告（本文档）	实验报告.docx
3	可复现性说明	附件 C / README.md
4	Stata 复现模块（do 文件与数据）	stata/
5	决策记录（D1–D21）	决策记录.md
6	每日工作日志	logs/
7	线下汇报（携带电脑）	10 月 15 日前